ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК 004.8

Отчет об исследовательском проекте на тему:

Генеративные рекомендательные системы

(промежуточный, этап 1)

Выполнили студенты:

группы БПМИ233, 3 курса	Гагарина Ульяна Юрьевна
группы БПМИ237, 3 курса	Казицин Михаил Юрьевич
группы БПМИ233, 3 курса	Пушкин Роберт Константинович

Принял руководитель проекта:

Лашинин Олег Андреевич
Ведущий исследователь-разработчик RecSys E-commerce
АО Тбанк

Москва 2026

Содержание

Аннотация **3**

1 Введение **4**

1.1 Описание предметной области 4

1.2 Постановка задачи и структура работы 4

2 Обзор литературы **6**

2.1 Рекомендательные системы с генеративным поиском 6

2.2 Семантические идентификаторы для ранжирования 7

2.3 Адаптация языковых моделей для промышленных рекомендаций 8

2.4 Генеративные рекомендации для следующей корзины 9

3 План дальнейшей работы **12**

3.1 Исследование методов генерации и оценки семантических идентификаторов . 12

3.2 Обучение линейных моделей на семантических идентификаторах 12

3.3 Обучение последовательностных моделей поверх семантических идентификаторов 12

3.4 Способы восстановления оригинальных объектов по Semantic ID 13

Аннотация

Рекомендательные системы в промышленных сценариях обычно строятся как двухэтапный пайплайн с генерацией или подбором кандидатов и ранжированием. Традиционные методы подбора кандидатов опираются на векторные представления и поиск ближайших соседей, но в последние годы развивается подход generative retrieval, где кандидаты порождаются моделью в виде последовательности дискретных токенов. В данной работе планируется исследовать базовый пайплайн рекомендаций с использованием семантических идентификаторов (Semantic IDs), получаемых дискретизацией семантических представлений объектов и обладающих иерархической структурой. Основное внимание будет уделено способам построения Semantic IDs, их оценке и связи качества кодирования с качеством рекомендательных моделей. Также будут рассмотрены общие практические аспекты применения Semantic IDs в различных классах рекомендательных моделей (линейных и последовательностных), а также задачи восстановления исходных объектов из Semantic IDs. Всё это это позволит оценить, насколько такой подход может служить основой для более универсальной модели рекомендаций для разных доменов.

Ключевые слова

Глубинное обучение, рекомендательные системы, разреживание моделей, семантические идентификаторы, дискретизация представлений, RQ-VAE, последовательные рекомендации

1 Введение

1.1 Описание предметной области

Рекомендательные системы являются ключевым компонентом многих онлайн-сервисов и обычно реализуются как двухэтапный процесс: быстрый этап генерации кандидатов (retrieval) отбирает небольшой набор потенциально релевантных объектов из большого каталога, после чего более сложная модель ранжирования (ranking) упорядочивает кандидатов для показа пользователю. В классических retrieval-подходах объекты и пользовательский контекст представляются векторными эмбеддингами, а кандидаты извлекаются с помощью поиска ближайших соседей (ANN). Такая схема хорошо масштабируется, но требует поддержки индекса и не всегда эффективно использует семантическую информацию об объектах, особенно в сценариях холодного старта и длинного хвоста. В последние годы развивается альтернативный подход generative retrieval, где retrieval формулируется как задача генерации: модель не ищет ближайшие объекты по вектору, а порождает идентификаторы рекомендуемых объектов как последовательность токенов. Для этого необходимы идентификаторы, которые несут структурированную информацию. Одним из вариантов являются семантические идентификаторы (Semantic IDs) - дискретные коды, получаемые из семантических представлений объектов (например, контентных эмбеддингов) с использованием методов дискретизации/квантования. Иерархическая структура таких кодов потенциально обеспечивает обобщение на новые объекты и даёт возможность управлять компромиссом между точностью и разнообразием.

1.2 Постановка задачи и структура работы

В данной работе перед студентами была поставлена задача построения и исследования базового рекомендательного пайплайна с использованием семантических идентификаторов - дискретных кодов объектов, получаемых из их семантических представлений и обладающих иерархической структурой. В качестве основной методологической опоры планируется использовать идею generative retrieval из работы «Recommender Systems with Generative Retrieval» [1], где этап генерации кандидатов рассматривается как задача генерации последовательности токенов, соответствующих объекту рекомендации.

Ожидается, что переход от "случайных"item_id к Semantic IDs позволит сделать пространство идентификаторов более структурированным и в некотром роде осмысленным, что потенциально улучшит переносимость знаний на новые объекты (cold-start) и работу с длинным хвостом (long-tail). Для проверки применимости подхода необходимо, во-первых, опреде-

лить и обосновать набор метрик, позволяющих оценивать качество получаемого разложения объектов в пространстве идентификаторов (например, степень коллизий, иерархичность и логическую согласованность префиксов, распределение частот токенов) и, во-вторых, установить связь этих характеристик с метриками качества рекомендательных моделей (Recall@K, NDCG@K и др.) на стандартных протоколах оценки.

Далее планируется провести серию экспериментов, позволяющих оценить применимость Semantic IDs в моделях разных классов. Во-первых, будет рассмотрен вариант обучения линейной i2i-модели (например, EASE) на данных, где объекты представлены семантическими идентификаторами, и выполнено сравнение с классическим вариантом на item_id, включая анализ поведения на хвосте распределения. Во-вторых, будет реализована последовательностная модель класса SASRec, адаптированная к входу в виде последовательностей Semantic IDs, и проведено сравнение с SASRec на исходных идентификаторах и/или с публикациями, где заявляется улучшение от использования семантической токенизации. Наконец, будет исследована практическая задача обратного отображения из Semantic ID в конкретный исходный объект: будут рассмотрены стратегии восстановления (по полному коду, по префиксу с дополнительным ранжированием, гибридные схемы) и оценён компромисс между точностью, неоднозначностью и вычислительными затратами.

2 Обзор литературы

2.1 Рекомендательные системы с генеративным поиском

В работе [1] представлен принципиально новый подход к построению рекомендательных систем, основанный на парадигме генеративного поиска (generative retrieval). Авторы отмечают, что современные промышленные системы рекомендаций обычно следуют двухэтапной схеме «поиск и ранжирование», где на этапе поиска (retrieval) используются модели с двумя энкодерами (dual-encoder). Такие модели отображают запрос (историю пользователя) и кандидатов в единое векторное пространство, а для извлечения кандидатов применяется приближенный поиск ближайших соседей (ANN). Несмотря на хорошую масштабируемость, этот подход требует создания и обслуживания отдельного индекса эмбеддингов всех объектов и демонстрирует ограниченную способность к обобщению на новые объекты (холодный старт) из-за зависимости от атомарных идентификаторов, не несущих семантической информации.

Для решения этих проблем предложена архитектура TIGER (Transformer Index for GEnerative Recommenders), в которой этап поиска переформулируется как задача генерации. Ключевая идея заключается в том, что модель не ищет ближайших соседей, а напрямую авторегрессионно порождает идентификатор следующего объекта. Реализация метода включает два последовательных этапа. На первом этапе для каждого объекта на основе его контентных признаков (название, описание и др.) создаётся семантический идентификатор (Semantic ID) - кортеж из m кодовых слов. Для этого семантический эмбеддинг объекта, полученный с помощью предобученного текстового энкодера (например, Sentence-T5), квантуется с использованием метода RQ-VAE (Residual-Quantized Variational AutoEncoder). Данный метод строит иерархическое представление, рекурсивно квантуя остатки и минимизируя функцию потерь $\mathcal{L}(x) := \|x - \hat{x}\|^2 + \sum_{d=0}^{m-1} \|\text{sg}[r_i] - e_{c_i}\|^2 + \beta\|r_i - \text{sg}[e_{c_i}]\|^2$, которая включает ошибку реконструкции и условия для обучения codebook'ов. На втором этапе история взаимодействий пользователя, представленная в виде последовательности семантических идентификаторов, подаётся на вход модели-трансформера, которая обучается напрямую предсказывать семантический идентификатор следующего объекта. Таким образом, параметры трансформера сами становятся семантическим индексом, что устраняет необходимость в отдельном внешнем индексе и дорогостоящем поиске по нему.

Эксперименты, проведённые на трёх наборах данных Amazon (Beauty, Sports and Outdoors, Toys and Games), показали, что предложенный метод существенно превосходит

современные модели последовательных рекомендаций (SASRec, BERT4Rec, S^3-Rec) по метрикам Recall@K и NDCG@K. Более того, благодаря семантической и иерархической природе идентификаторов, архитектура демонстрирует две новые важные возможности: эффективное решение задачи холодного старта за счёт рекомендации объектов, отсутствующих в истории взаимодействий, и управляемое увеличение разнообразия выдачи с помощью температурной дискретизации в процессе генерации токенов ID. С практической точки зрения данная работа задает основу нашего пайплайна: она демонстрирует, как Semantic IDs связывают контентную семантику и поведенческую задачу предсказания следующего объекта в единой модели.

2.2 Семантические идентификаторы для ранжирования

Если [1] использует Semantic IDs просто как инструмент для retrieval (генерации кандидатов), то работа [2] рассматривает следующий важный вопрос: как использовать семантические идентификаторы в ранжирующих моделях промышленного масштаба, где традиционно большую роль играют embedding tables по item ID, обеспечивающие способность к запоминанию (memorization). Авторы отмечают, что случайно хэшированные идентификаторы объектов в таких моделях хотя и обеспечивают эффективное запоминание популярных объектов, создают фундаментальное ограничение: они не позволяет модели обобщать знания между семантически схожими объектами. Это особенно критично для сценариев холодного старта и работы с длинным хвостом (long-tail) в условиях постоянно обновляющегося корпуса, содержащего миллиарды объектов, такого как видео на YouTube. Прямая замена случайных ID на плотные контентные эмбеддинги, как показали эксперименты, ведёт к значительной потере качества из-за утраты способности модели к запоминанию, а увеличение глубины модели для компенсации этого резко повышает вычислительные затраты на обслуживание.

В качестве решения авторы предлагают адаптировать для задач ранжирования семантические идентификаторы (Semantic IDs, SID), по аналогии с представленными в TIGER [1] для генеративного поиска. SID - это компактные дискретные последовательности, полученные путём остаточного квантования (RQ-VAE) замороженных контентных эмбеддингов объектов. Ключевой вклад работы заключается в разработке методов эффективной интеграции этих структурированных идентификаторов в ресурсоограниченные ранжирующие модели промышленного масштаба. Предлагается два подхода к представлению SID через таблицы эмбеддингов: N-граммный и на основе SentencePiece (SPM). Оба метода разбивают

последовательность SID на подслова (sub-pieces) для последующего хэширования в обучаемые эмбеддинги. В то время как N-граммы используют фиксированные по длине группы кодов, SPM динамически обучает словарь подслов переменной длины на основе распределения объектов в данных, что позволяет более эффективно использовать ограниченный размер таблицы эмбеддингов и лучше улавливать семантические связи.

Эксперименты проводились на реальной ранжирующей модели YouTube, работающей с корпусом в сотни миллионов видео. Результаты показали, что SPM-SID значительно превосходит базовое случайное хэширование ID по метрике CTR AUC для объектов холодного старта (CTR/1D), демонстрируя улучшенную способность к обобщению, при этом сохраняя или незначительно улучшая общий CTR. Таким образом, работа доказывает, что семантические идентификаторы, через методы вроде SPM, могут успешно заменить случайные ID в промышленном ранжировании, обеспечивая оптимальный баланс между запоминанием и семантическим обобщением.

2.3 Адаптация языковых моделей для промышленных рекомендаций

Работа [3] развивает идею "объекты как токены"дальше и предлагает фреймворк PLUM для адаптации предобученных больших языковых моделей (LLM) к промышленным рекомендациям. Авторы исходят из наблюдения, что доминирующая сегодня архитектура, основанная на гигантских таблицах эмбеддингов (LEM), хотя и эффективна для запоминания взаимодействий, принципиально ограничивает возможность использования более глубоких и сложных нейросетевых архитектур. Это создаёт разрыв с парадигмой LLM, где вычислительная мощность и способность к обобщению достигаются за счёт масштабирования самой нейронной сети, работающей с компактными семантическими токенами. Однако прямое применение LLM к рекомендациям оказывается неэффективным из-за их оторванности от предметной области, непонимания пользовательского поведения и проблем с интеграцией традиционных рекомендательных признаков.

Авторами предлагается трёхэтапный фреймворк PLUM. На первом этапе осуществляется токенизация объектов через улучшенную версию семантических идентификаторов (SIDv2). Улучшения включают слияние мультимодальных контентных эмбеддингов в единое представление, использование иерархических многоуровневых codebook'ов с прогрессивным маскированием для эффективности, а также ключевое нововведение - контрастивную регуляризацию, которая встраивает в структуру идентификаторов сигналы коллаборатив-

ной фильтрации, полученные из совместной встречаемости объектов в сессиях пользователей. Благодаря этому семантическое сходство, закодированное в SID, начинает отражать не только контентную близость, но и поведенческие паттерны.

Второй этап, продолженное предобучение (CPT), призван преодолеть разрыв между общими знаниями LLM и спецификой рекомендательного домена. Модель дообучается на смешанном корпусе, содержащем как последовательности пользовательских действий, представленные новыми SID-токенами, так и текстовые метаданные объектов. Это позволяет научить модель понимать контекст пользовательского поведения. Финальный этап - настройка для конкретной задачи, в данном случае для генеративного поиска. Модель обучается напрямую предсказывать последовательность SID следующего релевантного объекта на основе контекста пользователя, что исключает необходимость в отдельном индексе и поиске ближайших соседей, характерном для классических LEM-систем.

Проведённые эксперименты подтвердили эффективность каждого элемента этого подхода. Усовершенствования в генерации SIDv2, особенно использование контрастивной регуляризации, значительно повысили как уникальность идентификаторов, так и итоговое качество поиска. Сравнительные исследования однозначно показали критическую важность как этапа CPT, так и самой инициализации от предобученной LLM: эти факторы обеспечили существенный прирост в качестве рекомендаций и радикально ускорили сходимость модели. Исследование масштабируемости продемонстрировало, что более крупные модели закономерно показывают лучшее обобщение на новых данных. Практическим итогом этой работы стал успешный запуск PLUM в системе рекомендаций YouTube.

Мы планируем использовать [3] как источник идей для улучшения базовой схемы построения Semantic IDs и для постановки критериев их качества. Хотя в нашем проекте не ставится цель воспроизвести промышленный масштаб PLUM, предложенная логика позволяет сформулировать, какие свойства Semantic IDs потенциально важны для downstream-задач и какие характеристики токенизации стоит оценивать (иерархичность, уникальность/коллизии, согласованность с поведенческими связями).

2.4 Генеративные рекомендации для следующей корзины

В работе [4] рассматривается задача Next-Basket Recommendation (NBR) - прогнозирования следующего набора (корзины) товаров, которые пользователь вероятно купит, на основе последовательности его исторических покупок. Авторы указывают на два фундаментальных недостатка современных методов NBR, особенно основанных на глубоком обуче-

Dataset	Metric	FPMC	TIFU-KNN	BERT4Rec	DREAM	Beacon	Sets2Sets	CLEA	BART4Rec*	GenRec	Improv.
TaFeng	Recall@5	0.0639	0.0851	0.0876	0.0945	0.0837	0.0953	0.1269	0.1184	**0.1372***	+8.12%
	NDCG@5	0.0582	0.0774	0.0807	0.0834	0.0764	0.0897	0.1248	0.1132	**0.1297***	+3.93%
	Recall@10	0.0761	0.1262	0.1129	0.1182	0.1068	0.1362	0.1564	0.1421	**0.1682***	+7.54%
	NDCG@10	0.0621	0.0972	0.1064	0.1013	0.0941	0.1084	0.1457	0.1367	**0.1593***	+9.33%
ValuedShopper	Recall@5	0.0584	0.1369	0.0724	0.0667	0.0569	0.0814	0.1065	0.1354	**0.1591***	+16.21%
	NDCG@5	0.0633	0.1402	0.0893	0.0843	0.0751	0.1021	0.0979	0.1337	**0.1624***	+15.83%
	Recall@10	0.0947	0.2014	0.1082	0.0981	0.0849	0.1237	0.1621	0.2029	**0.2190***	+7.94%
	NDCG@10	0.1164	0.2136	0.1307	0.1235	0.1095	0.1564	0.1608	0.2059	**0.2287***	+7.07%
Electronics	Recall@5	0.0174	0.0295	0.0353	0.0324	0.0309	0.0291	0.0346	0.0342	**0.0361***	+2.27%
	NDCG@5	0.0098	0.0172	**0.0206**	0.0185	0.0174	0.0182	0.0197	0.0193	0.0204	-0.97%
	Recall@10	0.0209	0.0347	0.0438	0.0410	0.0398	0.0339	0.0442	0.0428	**0.0449**	+1.58%
	NDCG@10	0.0127	0.0224	0.0245	0.0229	0.0217	0.0217	0.0251	0.0244	**0.0256**	+1.99%

Рис. 2.1: Таблица 1: Общая производительность различных методов NBR на трёх датасетах.

нии. Во-первых, это проблема излишней гомогенизации (over-homogenization): модели, формирующие корзину как топ-K независимо ранжированных товаров, часто рекомендуют семантически схожие предметы (например, несколько пар обуви), в то время как реальные пользовательские корзины обычно содержат разнообразные, но взаимодополняющие товары. Во-вторых, большинство подходов агрегируют все товары корзины в единое векторное представление, теряя тем самым важную контекстную информацию об отдельных товарах (item-level) и их взаимосвязях внутри корзины.

Для решения этих проблем авторы предлагают принципиально новую генеративную парадигму для NBR и представляют модель GenRec (Generative next-basket Recommendation model). Ключевая идея заключается в том, чтобы не ранжировать товары, а авторегрессионно генерировать корзину товар за товаром, аналогично генерации текста в языковых моделях. Это позволяет явно учитывать взаимозависимости между уже сгенерированными и последующими товарами. Архитектура модели состоит из трёх основных компонентов. Двухуровневый энкодер кодирует историю пользователя: энкодер уровня товаров (Item-Level Encoder) обрабатывает полную последовательность всех исторических товаров с сохранением их порядка и принадлежности к корзинам, а энкодер уровня корзин (Basket-Level Encoder) работает с агрегированными представлениями корзин, выявляя долгосрочные предпочтения. Авторегрессионный декодер (Autoregressive Item-Level Decoder) является ядром модели. На каждом шаге он, используя маскированное внимание, учитывает уже сгенерированные товары новой корзины, а с помощью механизма перекрёстного внимания (cross-attention) запрашивает контекст от обоих энкодеров, что позволяет учитывать и историю, и формирующуюся структуру корзины. Важным подготовительным этапом является сортировка товаров внутри исторических корзин для формирования последовательности на вход энкодеру; эксперименты показали, что наилучшие результаты достигаются при сортировке по популярности товаров. Для улучшения обучения в условиях разреженности данных авторы применяют ауг-

ментации на уровне товаров и корзин, включая маскирование, обрезку последовательностей и обратный порядок.

Экспериментальная часть работы включает валидацию на трёх реальных датасетах: TaFeng, ValuedShopper и Electronics. Результаты, представленные в Таблице 1, демонстрируют, что GenRec стабильно превосходит все базовые методы, включая FPMC, TIFU-KNN, BERT4Rec, DREAM и CLEA, по метрикам Recall@K и NDCG@K. Более того, как показано в Таблице 3, GenRec обеспечивает значительно более высокое разнообразие рекомендаций (Diversity@10) по сравнению с другими методами глубокого обучения, что прямо подтверждает её способность решать проблему излишней гомогенизации. Абляционные исследования подтвердили важность каждого компонента модели: как двухуровневого кодирования, так и аугментаций данных. Таким образом, работа доказывает, что генеративный подход, явно моделирующий взаимосвязи товаров внутри корзины, позволяет достичь более точных и диверсифицированных рекомендаций в задаче NBR.

Мы планируем использовать идеи [4] как дополнительную мотивацию и источник инженерных приемов при построении нашего пайплайна на Semantic IDs. В частности, рассматривается возможность трактовать рекомендацию объекта как генерацию структурированного "кода"(последовательности токенов Semantic ID), где последующие токены уточняют выбор с учетом ранее сгенерированных. Кроме того, данный подход акцентирует, что переход к генеративной постановке требует аккуратной подготовки данных (например, выбора порядка внутри множества и применения аугментаций), а также отдельного анализа компромисса "точность–разнообразие". Эти аспекты тоже стоит взять в рассмотрение.

Methods	TaFeng		Electronics	
	Recall@10	Diversity@10	Recall@10	Diversity@10
GenRec	0.1682	5.0212	0.0449	4.8824
CLEA	0.1564	4.0175	0.0442	2.9172
BERT4Rec	0.1129	3.1403	0.0438	2.0186
TIFU-KNN	0.1262	4.7994	0.0347	4.0310

Рис. 2.2: Таблица 2: Результаты диверсификации на уровне категорий.

3 План дальнейшей работы

Исследование будет продолжено в рамках четырёх взаимосвязанных направлений.

3.1 Исследование методов генерации и оценки семантических идентификаторов

Данное направление является фундаментальным и будет реализовано всей командой. Основной фокус будет сосредоточен на разработке и валидации метрик для оценки качества генерации Semantic IDs. Предстоит исследовать, как измерять такие свойства разложения, как иерархическая согласованность, семантическая близость объектов с общими префиксами, информационная ёмкость и устойчивость к коллизиям. Ключевой задачей является установление корреляции между этими внутренними метриками качества SID и итоговым качеством рекомендательных моделей (Recall@K, NDCG@K), что позволит создавать идентификаторы, оптимальные для конечной задачи.

3.2 Обучение линейных моделей на семантических идентификаторах

В рамках этого направления Михаил Казицин исследует линейные модели с семантическими идентификаторами. Планируется провести сравнительный анализ линейных моделей, по типу EASE и классических моделей. Основные гипотезы для проверки: насколько такая модель сохраняет качество, демонстрирует ли улучшение на «хвосте» распределения (long-tail items) благодаря обобщающей способности семантических префиксов, и как её поведение меняется в условиях холодного старта.

3.3 Обучение последовательностных моделей поверх семантических идентификаторов

Данное направление исследуется Ульяной Гагариной и нацелено на воспроизведение и развитие результатов, представленных в статье о TIGER [1]. Планируется реализовать SASRec-подобную модель, принимающую на вход последовательности SID, и провести её сравнение с классическим SASRec, а также с опубликованными результатами SOTA-моделей. Цель - валидировать утверждение о превосходстве генеративного подхода на открытых наборах данных, а также исследовать влияние архитектурных особенностей и способов токе-

низации SID на итоговое качество последовательных рекомендаций.

3.4 Способы восстановления оригинальных объектов по Semantic ID

Практическое применение генеративных моделей, предсказывающих SID, сталкивается с задачей обратного отображения сгенерированного идентификатора на конкретный объект в каталоге. В данном направлении Роберт Пушкин проведет исследование методов и способов для возвращения назад от SID к оригинальным и разберется в том как можно потерять как можно меньше качества.

Список литературы (или источников)

[1] Shashank Rajput, Nikhil Mehta, Anima Singh, Raghunandan H. Keshavan, Trung Vu, Lukasz Heldt, Lichan Hong, Yi Tay, Vinh Q. Tran, Jonah Samost, Maciej Kula, Ed H. Chi, Maheswaran Sathiamoorthy. Recommender Systems with Generative Retrieval

[2] Anima Singh, Trung Vu, Nikhil Mehta, Raghunandan Keshavan, Maheswaran Sathiamoorthy, Yilin Zheng, Lichan Hong, Lukasz Heldt, Li Wei, Devansh Tandon, Ed H. Chi, Xinyang Yi. Better Generalization with Semantic IDs: A Case Study in Ranking for Recommendations

[3] Ruining He, Lukasz Heldt, Lichan Hong, Raghunandan Keshavan, Shifan Mao, Nikhil Mehta, Zhengyang Su, Alicia Tsai, Yueqi Wang, Shao-Chuan Wang, Xinyang Yi, Lexi Baugher, Baykal Cakici, Ed Chi, Cristos Goodrow, Ningren Han, He Ma, Romer Rosales, Abby Van Soest, Devansh Tandon, Su-Lin Wu, Weilong Yang, Yilin Zheng. PLUM: Adapting Pre-trained Language Models for Industrial-scale Generative Recommendations

[4] Wenqi Sun, Ruobing Xie, Junjie Zhang, Wayne Xin Zhao, Leyu Lin, Ji-Rong Wen. Generative Next-Basket Recommendation